

FoodAtlas：开放食品数据库中的营养结构、价格关系与标签数据质量可视分析系统

1. 项目背景

- “民以食为天”。食品消费不仅关系到个体健康，也与地区经济水平、食品工业结构、标签监管和消费者知情权密切相关。随着全球预包装食品数量快速增长，消费者在选择食品时往往需要同时了解营养成分、价格、产地、品牌、食品标签和健康评分等多维信息。然而，这些信息分散在产品包装、数据库和价格记录中，单纯依靠表格查询难以发现不同国家、品类和品牌之间的系统性差异。
- 本项目拟基于Open Food Facts公开食品数据库，构建FoodAtlas全球食品营养结构、价格关系与标签数据质量可视分析系统。系统希望从“食品是否健康”“健康食品是否更贵”“食品标签是否能正确反映食物的营养情况”“不同地区食品标签是否完整”“同类食品在不同国家是否存在明显差异”等问题出发，通过多视图联动和交互探索，帮助用户从全球尺度、品类尺度和单品尺度理解食品消费环境中的结构性特征。

2. 数据说明

- 本项目计划使用Open Food Facts项目下的四个公开数据集：
 - `product-database` 该数据集是本开源数据集的母集，包含全球预包装食品的产品信息、品牌、品类、国家、成分、营养成分、Nutri-Score、NOVA加工程度、标签、数据完整度和质量警告等字段。该数据集包含约457万条记录，其中food split 450万条，经初步分析后认为数据规模与信息类型能够支撑多层次、多维度可视分析。
 - `open-price` 该数据集包含食品价格记录，字段包括产品名、品类标签、价格、折扣信息、货币等约26.1万条价格记录，可与产品数据库通过产品条码关联，用于分析食品价格与营养质量、标签信息之间的关系。
 - `nutrient-detection-layout` 和 `ingredient-detection` 属于食品包装营养表和成分表的标注数据集，主要包含图像、OCR token、bbox、NER 标签和成分文本标注等信息。由于其样本规模较小，且并不覆盖product-database中的大多数产品，本项目不将其用于国家、品类或品牌层面的总体统计，而仅作为辅助数据，用于解释营养字段和成分字段从包装文本到结构化数据的可能来源。
- 目前数据集中主要存在内容包含部分非食品商品，数据缺项较为严重，语言/币种/食品标准不统一，无用属性较多，食品来源国家具有局部性等问题，因此考虑对数据集进行针对性预处理：
 - 压缩数据集规模，仅使用数据属性类别与内容较为完整的数据部分
 - 过滤非食品记录，优先使用food split；
 - 统一国家、品类、品牌、标签等多值字段；
 - 从nutriments字段中提取每100g/100ml的糖、盐、脂肪、饱和脂肪、蛋白质、能量等指标；
 - 依据code/product_code关联产品信息与价格记录；
 - 对不同货币和计量单位进行标准化处理；

- 过滤缺失严重或明显异常的价格、营养记录；
- 构造派生指标，如健康评分、标签完整度、价格-营养性价比、同类产品异常程度等。

3. 分析任务定义

- 根据项目数据集的结构，暂时拟定下面的三个主要分析任务：

3.1. 开放食品样本的营养结构与健康指标覆盖分析

- 基于 `product-database` 中具有可用营养字段的食品样本，分析不同国家、食品品类和品牌在营养成分、能量、Nutri-Score和NOVA加工程度等指标上的分布差异，从而进一步探究各个国家食品营养结构与健康程度的整体特征与世界分布特征。

3.2. 开放食品标签数据质量与产品异常检测

- 基 `product-database` 中的 `completeness`、`data_quality_warnings_tags`、`data_quality_errors_tags`、营养字段覆盖情况、成分文本覆盖情况等字段，分析不同国家、品类和品牌下食品样本的数据完整性差异。在用户选定国家、品类或品牌后，系统对同类产品进行多维对比，识别高糖高盐、高加工等级、健康评分较差、数据完整性较低、质量警告较多，或价格明显偏离同类水平的产品。

3.3. 主要样本国家的食品价格-营养关系分析

- 基于 `open-price` 数据集，以价格记录较充足的国家为主要分析对象，探索在使用同一币种的地区，同一食品品类内部，食品价格与营养质量之间的关系，重点比较同类产品中价格、糖盐脂含量、Nutri-Score、NOVA加工程度之间的关联，尝试以价格为因变量，价格以外的属性为自变量探究食品营养结构对价格的影响，契合“健康食品是否更贵”的研究主题。

4. 设计方案

4.1. 分析流程

- 系统采用“全球概览-标签诊断-价格关联-产品解释”的分析流程。首先，系统基于 `product-database` 从全球视角展示开放食品样本的国家分布、品类分布、营养字段覆盖率和健康指标分布。用户可以先观察不同国家和品类中的食品样本Nutri-Score、NOVA 加工程度、糖盐脂等营养指标差异，从而形成对开放食品样本整体结构的认识。
- 在此基础上，系统进入标签透明度分析阶段。系统利用 `product-database` 中的字段信息分析产品层面的数据完整度，并另一方面结合 `nutrient-detection-layout` 和 `ingredient-detection` 中的框选信息，展示营养表和成分表从包装图像到结构化数据的抽取过程，解释标签信息缺失、抽取困难和质量警告产生的可能原因。
- 随后，系统进入价格-营养关联分析阶段。系统基于 `open-prices` 中的价格、币种、日期和地点信息，通过`product_code`与 `product-database` 中的`code`字段关联。考虑到不同国家、币种和地区价

格记录分布不均，系统主要在价格记录较充分且币种一致的国家或地区内进行分析，比较同一食品品类内部价格与糖盐脂、Nutri-Score、食品加工程度等指标之间的关系。

- 最后，系统提供产品详情解释。用户可以从国家、品类、品牌或异常点进入单个产品，查看该产品的营养结构、健康指标、标签完整度、质量警告、营养表/成分表抽取样例以及可匹配价格记录。通过这种方式，系统形成从总体分布到标签机制、再到价格关联和单品解释的分析闭环。

4.2. 视图设计

- 计划依据分析任务设计下述视图：
 - 全球食品样本概览地图**：该视图以国家为基本单元，以热力图形式展示product-database中食品样本数量、营养字段覆盖率、有效Nutri-Score覆盖率等指标。颜色用于表示标签完整度或健康指标覆盖率，悬浮提示展示该国家的样本量、主要品类和可用营养字段比例，帮助用户判断不同国家样本的规模与可信度。
 - 主要国家地区营养结构视图**：该视图使用热力图、旭日图或堆叠条形图展示食品品类结构。以热力图为例，以颜色深度编码不同地区食物平均糖含量、盐含量、脂肪含量、NOVA等级或Nutri-Score分布，用户通过选择不同的营养指标来获取全球不同地区食品的平均指标情况。对于选定的国家/品类/品牌，单独使用平行坐标、箱线图或散点矩阵展示选定国家/品类/品牌下产品的能量、糖、盐、脂肪、饱和脂肪、蛋白质、Nutri-Score和加工程度等指标。
 - 产品异常散点图**：该视图基于 product-database 中的数据，将每个产品表示为一个点，通过纵横轴映射价格、糖盐脂含量、Nutri-Score、NOVA等指标，并通过颜色、大小和透明度编码品类、品牌、价格记录数量和数据完整度。散点图能够直观呈现产品在同类样本中的聚集和偏离情况，帮助用户快速发现价格较高但营养质量较差、高糖高盐且加工等级较高等候选异常产品。
 - 价格-营养关系视图**：该视图基于 open-prices 与 product-database 的关联结果，展示同一币种、同一品类内部价格与营养指标之间的关系。散点图中每个点表示一个可匹配产品，横轴可为价格，纵轴可切换为Nutri-Score、糖含量、盐含量等营养指标，点的大小表示价格记录数量，从而根据图中的三点分布判断价格与营养指标的关联程度。
 - 产品详情解释视图**：从数据库中选取信息齐全，有代表性的部分食品样本完成该视图，展示被选中产品的名称、品牌、国家、品类、营养成分、Nutri-Score、成分文本、营养表/成分表抽取样例以及可匹配价格记录。同时展示该产品在同国家、同品类产品中的分位数位置，例如糖含量分位、盐含量分位、标签完整度分位和价格分位。

4.3. 交互设计

- 初步的交互设计如下：
 - 系统以国家、食品品类、品牌和产品作为核心交互对象。用户在全球食品样本概览地图中选择某一国家或地区后，主要国家地区营养结构视图、产品异常散点图、价格-营养关系视图和产品详情列表将同步更新，仅展示当前国家或地区下的数据样本。若用户选择品类，产品异常散点图和价格-营养关系视图将仅展示该品类下的产品；若用户切换营养指标，如糖含量、盐含量、脂肪含量、能量、Nutri-Score或NOVA加工程度，地图和营养结构视图中的颜色编码、排序结果和统计摘要也会随之更新。

- 用户可以在**产品异常散点图**中切换横纵轴变量，例如价格、糖含量、盐含量、脂肪含量、Nutri-Score、NOVA加工程度和数据完整度。散点颜色用于区分品类或品牌，点大小可表示价格记录数量或扫描次数。用户通过框选或点击远离主体点云的样本，系统会将这些产品标记为候选异常样本，并在产品列表和详情视图中展示其具体营养结构、价格水平、数据完整度和质量警告。
- 用户在**价格-营养关系视图**中可以选择币种、国家和食品品类，系统仅保留能够通过 `product_code` 与 `product-database` 成功关联的价格记录。用户可以切换纵轴指标，如 Nutri-Score、糖含量、盐含量、脂肪含量或 NOVA加工程度，用于观察同一品类内部价格与营养指标之间的关系。
- 用户点击某个品牌或产品后，系统进入产品详情解释。详情视图展示该产品的名称、品牌、国家、品类、营养成分、Nutri-Score、NOVA加工程度等指标。同时，系统会将该产品与同国家、同品类产品进行比较，展示其糖含量、盐含量、脂肪含量、价格和数据完整度的分位数位置，帮助用户判断该产品是否真正偏离同类样本。

5. 当前进展与后续计划

- 当前本组已经完成了组内分工与项目的选题，数据集的下载与初步分析，经过讨论确定了需要完成的分析任务与初版设计方案，即将对数据进行预处理与分类，并按分析任务与视图设计逐个完成。